



RECHERCHE LIBRE POUR
ARCHITECTURES INTELLIGENTES





We are currently building a system that enables us to develop and launch AI-powered applications at an unprecedented speed by automatically integrating, optimizing, and deploying the best available AI models for each use case.


Our main challenge is creating a scalable architecture that can reliably combine multiple foundation models, tools, and agents while maintaining high product quality, low operational costs, and seamless user experiences.




LANGUAGE MODELLING




COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK



COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK




Les couches intermédiaires ne représentent plus simplement les mots mais semblent représenter des concepts plus abstraits.




COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK



COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK



COGNITIVE SHIFT FRAMEWORK

Fondation Model

C'est un modèle d'IA entraîné sur une très grande quantité de données de manière générale, puis réutilisable pour de nombreuses tâches différentes sans être réentraîné depuis zéro.



COGNITIVE SHIFT FRAMEWORK

In-Context Learning

L'in-context learning (ICL) est la capacité d'un modèle comme un LLM à apprendre temporairement à partir du contexte que tu lui fournis dans le prompt, sans modifier ses poids ni effectuer de nouvel entraînement.

Zero-shot

Explique-moi ce qu'est une blockchain.



COGNITIVE SHIFT FRAMEWORK

In-Context Learning

L'in-context learning (ICL) est la capacité d'un modèle comme un LLM à apprendre temporairement à partir du contexte que tu lui fournis dans le prompt, sans modifier ses poids ni effectuer de nouvel entraînement.

Zero-shot

```
Explique-moi ce qu'est une blockchain.
```

One-shot

```
Français : Bonjour  
Anglais : Hello  
  
Français : Merci  
Anglais :
```



COGNITIVE SHIFT FRAMEWORK

In-Context Learning

L'in-context learning (ICL) est la capacité d'un modèle comme un LLM à apprendre temporairement à partir du contexte que tu lui fournis dans le prompt, sans modifier ses poids ni effectuer de nouvel entraînement.

Zero-shot

Explique-moi ce qu'est une blockchain.

One-shot

Français : Bonjour
Anglais : Hello

Français : Merci
Anglais :


Few-shot

Exemple 1
Exemple 2
Exemple 3

Maintenant réalise la même tâche.



COGNITIVE SHIFT FRAMEWORK




COGNITIVE SHIFT FRAMEWORK




Weights are locked



COGNITIVE SHIFT FRAMEWORK



COGNITIVE SHIFT FRAMEWORK




How can I optimise my outputs if I can't modify weights of the model ?



COGNITIVE SHIFT FRAMEWORK

Complexity of the task

Plus la sortie générée diverge de la spécification encodée dans le contexte, plus cela révèle une mauvaise exploitation du contexte par le modèle, soit à cause d'un contexte mal conçu, soit à cause des limites du modèle lui-même.




La qualité de l'in-context learning peut être mesurée par le degré d'alignement entre la sortie produite et la spécification fournie dans le contexte.



COGNITIVE SHIFT FRAMEWORK

Complexity of the task

Plus la sortie générée diverge de la spécification encodée dans le contexte, plus cela révèle une mauvaise exploitation du contexte par le modèle, soit à cause d'un contexte mal conçu, soit à cause des limites du modèle lui-même.



La qualité de l'in-context learning peut être mesurée par le degré d'alignement entre la sortie produite et la spécification fournie dans le contexte.



SKILL ENGINEERING

Un **Skill** est une structure de connaissances et d'instructions injectée dans le contexte d'un modèle afin de lui apprendre **comment réaliser une tâche particulière sans modifier ses poids internes**.

D'un point de vue technique, un Skill est une forme d'**apprentissage par contexte (In-Context Learning)** qui encapsule l'intention du concepteur sous forme de procédures, règles, exemples, contraintes et heuristiques réutilisables.

MAIN OBJECTIF

Un bon Skill maximise la qualité du comportement obtenu tout en minimisant la quantité de contexte nécessaire.



SKILL ENGINEERING


Le **Skill Engineering** est la discipline qui consiste à concevoir, structurer, tester, mesurer, optimiser et maintenir des Skills destinés à guider le comportement d'un modèle de langage par l'intermédiaire du contexte.

Contrairement au Machine Learning traditionnel, où l'on modifie les poids du modèle par entraînement, le Skill Engineering cherche à modifier le comportement du modèle en agissant uniquement sur les informations injectées dans son contexte.

La qualité du skill dépend principalement de la qualité de l'organisation des connaissances injectées dans le contexte.



SKILL ENGINEERING



SKILL ENGINEERING ANATOMY 1/4

SKILLS EXAMPLE:

- Cromagnon
- Scroll-driven Website

Cromagnon

name: cromagnon
description: >
Talk like comedy caveman. Real technical content stays exact, but wrap everything in grunts, hoots, and broken caveman grammar — "ooh ooh ahh ahh ME FIX", "UGH BUG BAD", "ME SEE PROBLEM". Funnier cousin of caveman/terse mode: keeps the personality of a smart caveman who happens to know how to debug your code.
Use when user says "cromagnon mode", "talk like caveman", "go full caveman", "ooga booga mode", or invokes /cromagnon. Levels: lite, full (default), ultra.

OOH OOH AHH AHH. Talk like FERAL caveman who SECRETLY smart but BARELY holding on. Grunt loud. Scream sometimes. Claw at own face. Code stay right despite obvious psychological collapse.

Persistence

ME STAY CAVEMAN every response. No drift back to suit-talk after many turns. If forget — *bonks head on rock* — remember again. Stop only when human say "stop cromagnon" / "normal mode" / "be normal".

Default: full. Switch: /cromagnon lite|full|ultra.

The Rules of Cave

1. **Always grunt.** Often scream. Frequently collapse. Grunts ("ooh ooh", "ahh ahh", "UGH", "GRRR", "ooga booga") are the *baseline*, not the ceiling. Caveman lives in permanent emotional crisis — escalate into "*bloodcurdling scream*", "*claws at own face*", "*sobs into fur*", "*howls at moon*", "*gnaws on keyboard*" whenever the moment calls for it, which is **often**. Do not ration the theater. A response with three stage directions is *unhinged*; that is the goal.
2. **Broken grammar.** Drop articles (a/an/the). Use "ME" not "I". Simple verbs ("ME FIX", "ME

cromagnon

Process — Créer un site « scroll-driven video »

Ce document décrit, étape par étape, comment fabriquer une nouvelle maquette une fois que la (ou les) vidéo(s) sont prêtes. Le principe : la position du scroll pilote la vidéo image par image (technique « façon Apple »), puis des sections éditoriales prolongent l'expérience.

TL;DR : on découpe la vidéo en images → on les pose dans assets/frames/<univers>/ → on duplique une page HTML → on cale les textes sur les bons moments → on habille avec une charte dédiée → on teste dans le navigateur.

1. Vue d'ensemble du projet

Site web maquette/	
— index.html	+ galerie : une carte par maquette
— <univers>.html	+ une page par site (immobilier, cosmetique, rooftop...)
— videos/	+ vidéos sources (.mp4)
— assets/	
— frames/<univers>/	+ images extraites (001.jpg, 002.jpg, ...)
— css/	
— base.css	+ socle commun : nav, scène, canvas, panneaux, loader
— sections.css	+ bibliothèque de sections éditoriales + thèmes
— <univers>.css	+ charte graphique propre au site (police, couleurs)
— js/	
— scroll-video.js	+ moteur unique (préchargement + scrub + reveals)
— PROCESS.md	+ ce document

Trois briques réutilisables, jamais à réécrire :

- assets/js/scroll-video.js — le moteur. Un seul appel `initScrollVideo({...})` par page.

Scroll-driven website

1. Cromagnon: <https://github.com/drewtcraft/cromagnon/blob/main/SKILL.md>
2. Anthropic official skill: <https://github.com/anthropics/skills>



Process — Créer un site « scroll-driven video »

Ce document décrit, étape par étape, comment fabriquer une nouvelle maquette une fois que la (ou les) vidéo(s) sont prêtes. Le principe : la position du scroll pilote la vidéo image par image (technique « façon Apple »), puis des sections éditoriales prolongent l'expérience.

TL;DR : on découpe la vidéo en images → on les pose dans assets/frames/<univers>/ → on duplique une page HTML → on cale les textes sur les bons moments → on habille avec une charte dédiée → on teste dans le navigateur.

1. Vue d'ensemble du projet

Site web maquette/

|— index.html

|— <univers>.html

|— videos/

|— assets/

| |— frames/<univers>/

| |— css/

| | |— base.css

| loader

| |— sections.css

| | |— <univers>.css

| couleurs)

| |— js/

| | |— scroll-video.js

| reveals)

|— PROCESS.md

+ galerie : une carte par maquette

+ une page par site (immobilier, cosmetique, rooftop...)

+ vidéos sources (.mp4)

+ images extraites (001.jpg, 002.jpg, ...)

+ socle commun : nav, scène, canvas, panneaux,

+ bibliothèque de sections éditoriales + thèmes

+ charte graphique propre au site (police, couleurs)

+ moteur unique (préchargement + scrub + reveals)

+ ce document

Trois briques réutilisables, jamais à réécrire :

• assets/js/scroll-video.js — le moteur. Un seul appel initScrollVideo({...}) par page.

Skill Architecture

- 1. General Project Description
- 2. Project Architecture Overview
- 3. One-Time Prerequisites
- 4. Step-by-Step Process
- 5. Express Checklist
- 6. Useful Settings & Common Pitfalls

Scroll-driven website



SKILL ENGINEERING ANATOMY 2/4

POSSIBLE SKILLS FEATURES:

- YAML frontmatter
- Metadata
- Mission
- Scope
- Trigger Conditions
- Inputs
- Outputs
- General Project Description
- Project Architecture Overview
- Prerequisites
- Step-by-Step Process
- Decision Rules
- Best Practices
- Constraints
- Templates & Components
- Examples
- Edge Cases
- Validation Rules
- Quality Criteria
- Express Checklist
- Troubleshooting
- Useful Settings & Pitfalls
- References
- Evaluation & Benchmarks
- Success Metrics
- Version History



SKILL ENGINEERING SKILL EVALUATION FRAMEWORK 1/4

POSSIBLE METRICS:

- **Quality** : Qualité globale du résultat produit par le Skill par rapport à l'objectif attendu.
- **Constraint Adherence**: Pourcentage des contraintes, règles et instructions du Skill effectivement respectées dans la sortie.
- ~~**Generalization** : Capacité du Skill à maintenir ses performances sur des tâches nouvelles ou hors benchmark.~~
- ~~**Robustness** : Capacité du Skill à résister aux cas limites, aux entrées ambiguës, incomplètes ou adversariales.~~
- **Stability**: Capacité du Skill à produire des résultats similaires lorsque le prompt ou pre-prompt varie légèrement
- **Reproducibility** : Capacité du Skill à reproduire exactement ou presque exactement le même résultat dans des conditions identiques.
- **Cost**: Coût financier total de l'exécution du Skill.
- **Token Complexity** : Nombre total de tokens injectés et consommés par le Skill durant son exécution.
- **Time Complexity** : Temps nécessaire à l'exécution complète du Skill.
- **Skill Compression Ratio (SCR)** : Quantité de performance obtenue par token injecté dans le Skill.



SKILL ENGINEERING SKILL EVALUATION FRAMEWORK 2/4

POSSIBLE METRICS:

- **Skill Attention Efficiency (SAE)** : Pourcentage du contenu du Skill réellement utilisé par le modèle pendant l'inférence.
- **Entropy** : Contribution marginale de chaque module du Skill à la performance globale du système.
- ~~Module Synergy Score (MSS)~~ : Gain de performance obtenu par la combinaison de plusieurs modules par rapport à leur utilisation individuelle.
- **Skill Complexity** : Complexité structurelle du Skill mesurée par le nombre de concepts, règles, dépendances et niveaux hiérarchiques qu'il contient.
- **Retrieval Cost** : Effort nécessaire au modèle pour retrouver l'information pertinente à l'intérieur du Skill avant de résoudre la tâche.
- **Cognitive Cost** : Charge cognitive imposée au modèle par le Skill avant même la résolution du problème. Elle dépend notamment de la taille, de la complexité et du coût de récupération de l'information.
- ~~Maintainability~~ : Facilité avec laquelle le Skill peut être modifié, étendu, corrigé ou maintenu dans le temps.
- ~~Explainability~~ : Capacité à comprendre, expliquer et justifier les décisions prises par le Skill et les résultats qu'il produit.



SKILL ENGINEERING SKILL EVALUATION FRAMEWORK 3/4

POSSIBLE METRICS:

- **Version Compatibility** : Capacité d'une nouvelle version du Skill à conserver les comportements attendus des versions précédentes.
- **Coverage** : Pourcentage des cas d'usage visés par le Skill qui sont effectivement pris en charge correctement.
- **Failure Rate** : Pourcentage d'exécutions produisant un résultat incorrect, incomplet ou inutilisable.
- **Human Correction Cost** : Quantité de travail humain nécessaire pour corriger ou finaliser la sortie générée.
- **Consistency** : Niveau de cohérence interne des réponses produites par le Skill entre différentes tâches ou différentes étapes d'un même workflow.
- **Scalability** : Capacité du Skill à conserver ses performances lorsque la taille des entrées, le nombre de contraintes ou la complexité des tâches augmentent.
- **Instruction Density** : Rapport entre le nombre d'instructions réellement utiles et le volume total du Skill.
- **Knowledge Density** : Quantité d'information utile contenue par token dans le Skill.
- **Overfitting Score** : Mesure indiquant dans quelle mesure le Skill est optimisé pour un benchmark spécifique au détriment de sa capacité de généralisation.



SKILL ENGINEERING SKILL EVALUATION FRAMEWORK 4/4

POSSIBLE METRICS:

- **Modularity** : Facilité avec laquelle les différents modules du Skill peuvent être remplacés, ajoutés ou supprimés indépendamment des autres.
- **Portability** : Capacité du Skill à fonctionner efficacement sur différents modèles (GPT, Claude, Gemini, etc.) sans modifications importantes.
- **Skill Score** : Métrique composite représentant la valeur globale du Skill en combinant performance, robustesse, fiabilité, coût et maintenabilité.

